

ЛЕКЦИЯ К ЛАБОРАТОРНОЙ РАБОТЕ

Многорукий бандит и Cross-Entropy Method

Никитин Пётр Владимирович
Кафедра искусственного интеллекта
Финансовый университет

RL

теория →
эксперимент → **ВЫВОД**

Что студент должен уметь после работы

Бандит

Объяснить
exploration/exploitation, reward
и cumulative regret.

CEM

Построить элитную выборку
траекторий и обновить
политику.

Исследование

Зафиксировать гипотезу,
seed, метрики и
доверительный интервал.

Математическая основа

$$Q_{n+1}(a) = Q_n(a) + 1/N_n(a) \cdot [R_n - Q_n(a)]$$

$$\text{Regret}(T) = T\mu^* - \sum_t \mu(a_t)$$

$$\text{UCB}_t(a) = Q_t(a) + c\sqrt{(\ln t)/N_t(a)}$$

Regret измеряет цену неоптимальных действий; высокая награда сама по себе не показывает качество исследования.

Три стратегии exploration

Редактируемая архитектурная схема



Все стратегии получают один и тот же поток Bernoulli-наград и сравниваются по regret и доле оптимальных действий.

Cross-Entropy Method

Математическая основа


$$\gamma_i = \text{Quantile}_q(\{G(\tau_1), \dots, G(\tau_N)\})$$

$$D_{\text{elite}} = \{(s_t, a_t) \in \tau_i \mid G(\tau_i) \geq \gamma_i\}$$

$$\theta_{i+1} = \arg\max_{\theta} \sum_{(s,a) \in D_{\text{elite}}} \log \pi_{\theta}(a|s)$$

CEM превращает лучшие траектории в supervised-выборку для следующей версии политики.

Редактируемая архитектурная схема



Увеличение пространства действий ускоряет кратчайший маршрут, но усложняет исследование и делает элитные эпизоды реже.

Пример результатов

Сравнение на одинаковых данных и временных границах

Эксперимент	Параметр	Метрика 1	Метрика 2
Thompson	1000 шагов	regret 18,6	optimal 91%
UCB1	1000 шагов	regret 31,4	optimal 84%
CEM-8	N=100, q=75%	success 92%	15,4 хода
CEM-12	N=100, q=75%	success 71%	17,2 хода

Одна итерация CEM

Фрагмент, который студент должен уметь объяснить

```
sessions = [generate(env, policy)
             for _ in range(batch)]
threshold = np.quantile(returns, q)
elite = [s for s in sessions
         if s.reward >= threshold]
policy.fit(states(elite), actions(elite))
```

Что происходит

1. Политика генерирует траектории.
2. Квантиль задаёт порог.
3. Из элитных траекторий берутся пары (s,a).
4. Политика максимизирует их log-likelihood.

Сначала ответьте без подсказок

- 1. Что уменьшает cumulative regret? А) частые случайные действия В) быстрое выявление лучшей руки С) рост дисперсии
- 2. Почему $q=95\%$ может остановить SEM? А) мало элиты В) слишком много действий С) нет reward
- 3. Что сравнивать между 4, 8 и 12 действиями?

Разбор мини-теста

Проверьте рассуждение, а не только букву ответа

- 1. В: лучшая рука должна чаще выбираться после достаточного исследования.
- 2. А: слишком мало пар (s,a) делает обновление нестабильным.
- 3. Success rate, возврат, длину маршрута, частоты действий и устойчивость по seed.

Выводы и переход к лабораторной №2

От малых задач к временному ряду

- Бандит показывает цену исследования без состояния.
- СЕМ вводит траекторию и параметризованную политику.
- В лабораторной №2 состояние уже формируется из реальных финансовых показателей.
- Исследовательская дисциплина сохраняется: гипотеза → validation → один финальный test.