

ЛЕКЦИЯ К ЛАБОРАТОРНОЙ РАБОТЕ

Q-learning, SARSA и Expected SARSA на данных MOEX

Никитин Пётр Владимирович
Кафедра искусственного интеллекта
Финансовый университет

RL

теория →
эксперимент → **ВЫВОД**

Что студент должен уметь после работы

TD control

Вывести три TD-цели и различить on-policy и off-policy.

Финансы

Построить причинные показатели без утечки будущего.

Эксперимент

Сравнить алгоритмы на одном test 2025 с комиссией.

Математическая основа


$$\text{Q-learning: } y = r + \gamma \max_{a'} Q(s', a')$$

$$\text{SARSA: } y = r + \gamma Q(s', a'), \quad a' \sim \pi(\cdot | s')$$

$$\text{Expected SARSA: } y = r + \gamma \sum_{a'} \pi(a' | s') Q(s', a')$$

Общее обновление: $Q(s, a) \leftarrow Q(s, a) + \alpha [y - Q(s, a)]$. Различается только bootstrap.

Редактируемая архитектурная схема



Состояние должно быть достаточно компактным: произведение числа корзин быстро увеличивает размер Q-таблицы.

Математическая основа


$$r_t = w_t R_{t+1} - c |w_t - w_{t-1}| - \lambda \max(0, -w_t R_{t+1})$$

$$RSI = 100 - 100 / (1 + \text{AvgGain} / \text{AvgLoss})$$

$$MACD = EMA_{12}(C) - EMA_{26}(C); \quad ATR = MA_{14}(TR)$$

Решение дня t использует только признаки, рассчитанные не позднее t ; доходность $t+1$ появляется лишь в награде.

Редактируемая архитектурная схема



Нельзя случайно перемешивать ряд, обучать пороги дискретизации на test или выбирать алгоритм по test-Sharpe.

Иллюстративное сравнение SBER

Сравнение на одинаковых данных и временных границах

Политика	Доходность	Sharpe	Max DD
Q-learning	12,8%	0,91	14,7%
SARSA	10,9%	0,84	12,2%
Expected SARSA	13,5%	1,02	11,8%
Buy & Hold	9,6%	0,71	19,4%

Фрагмент, который студент должен уметь объяснить

```
if algo == "q_learning":  
    b = Q[next_state].max()  
elif algo == "sarsa":  
    b = Q[next_state, next_action]  
else:  
    b = probs @ Q[next_state]  
Q[state, action] += alpha * (  
    reward + gamma*b - Q[state, action])
```

Что происходит

Q-learning оптимизирует жадную целевую политику.

SARSA учитывает исследовательское следующее действие.

Expected SARSA снижает дисперсию, усредняя по ϵ -жадной политике.

Сначала ответьте без подсказок

- 1. Какой метод off-policy? A) Q-learning B) SARSA C) оба on-policy
- 2. Где рассчитываются пороги дискретизации?
- 3. Почему высокий return не гарантирует лучшую модель?

Разбор мини-теста

Проверьте рассуждение, а не только букву ответа

- 1. А: Q-learning использует max по целевой жадной политике.
- 2. Только на train; validation/test применяют сохранённые пороги.
- 3. Нужно учитывать Sharpe, drawdown, turnover, комиссию и устойчивость по seed.

Когда таблицы уже недостаточно

- Табличные методы прозрачны: каждое состояние и Q-значение можно проверить.
- Цена прозрачности — грубая дискретизация и экспоненциальный рост числа состояний.
- DQN заменяет таблицу аппроксиматором $Q(s,a;\theta)$, сохраняя TD-логику.
- Данные, временные границы и baseline остаются теми же — меняется только класс модели.