

ЛЕКЦИЯ К ЛАБОРАТОРНОЙ РАБОТЕ

DQN, Double DQN и Dueling Double DQN

Никитин Пётр Владимирович
Кафедра искусственного интеллекта
Финансовый университет

RL

теория →
эксперимент → **ВЫВОД**

Что студент должен уметь после работы

Аппроксимация

Перейти от Q-таблицы к нейросети $Q(s,a;\theta)$.

Стабилизация

Объяснить replay buffer и target network.

Финансовый test

Сравнить DQN-семейство на MOEX без утечки.

Функция потерь DQN

Математическая основа


$$y_t = r_t + \gamma(1 - \text{done}) \max_{a'} Q(s_{t+1}, a'; \theta^-)$$

$$L(\theta) = E_D [(y_t - Q(s_t, a_t; \theta))^2]$$

$$\theta^- \leftarrow \theta \text{ каждые } K \text{ шагов; } (s, a, r, s') \sim \text{ReplayBuffer}$$

Replay разрушает временную корреляцию, target network замедляет движение цели.

Редактируемая архитектурная схема



Нейросеть интерполирует между похожими состояниями, но требует контроля масштаба признаков и переобучения.

Double и Dueling DQN

Математическая основа


$$\text{DDQN: } a^* = \arg\max_a Q(s', a; \theta); \quad y = r + \gamma Q(s', a^*; \theta^-)$$

$$Q(s, a) = V(s) + A(s, a) - \text{mean}_{a'} A(s, a')$$

$$\text{Huber}(\delta) = \frac{1}{2}\delta^2, \quad |\delta| \leq 1; \quad |\delta|^{-\frac{1}{2}} \text{ иначе}$$

Double разделяет выбор и оценивание; dueling разделяет ценность рыночного состояния и преимущество действия.

Редактируемая архитектурная схема



В test $\epsilon=0$, параметры заморожены, каждое действие и причина записываются в протокол.

Сравнение архитектур

Сравнение на одинаковых данных и временных границах

Модель	Сильная сторона	Риск	Проверка
DQN	простая база	overestimation	Q-scale
Double DQN	меньше смещение	две сети	target sync
Dueling DDQN	state value отдельно	сложнее head	абляция V/A
Buy & Hold	нет обучения	рыночный риск	единый test

Double DQN target

Фрагмент, который студент должен уметь объяснить

```
with torch.no_grad():  
    next_action = online(next_s).argmax(1)  
    next_q = target(next_s).gather(  
        1, next_action[:, None])  
    y = r + gamma*(1-done)*next_q  
    q = online(s).gather(1, a[:, None])  
    loss = F.smooth_l1_loss(q, y)
```

Что происходит

Online-сеть выбирает a^* .

Target-сеть только оценивает
выбранное действие.

Так уменьшается
систематическое завышение $\max$
Q при шумных оценках.

Сначала ответьте без подсказок

- 1. Зачем нужна target network?
- 2. Что исправляет Double DQN?
- 3. Почему test нельзя запускать многократно при выборе гиперпараметров?

Разбор мини-теста

Проверьте рассуждение, а не только букву ответа

- 1. Делает TD-цель медленно меняющейся и стабилизирует обучение.
- 2. Снижает overestimation, разделяя выбор и оценивание действия.
- 3. Возникает адаптация к test и оптимистическая оценка обобщения.

Выводы и переход к MARL

От одной позиции к портфелю

- DQN масштабируется к непрерывным признакам, но усложняет верификацию.
- DDQN и dueling head решают разные источники нестабильности.
- Для портфеля появляется вектор весов, корреляции и конфликт целей.
- Лабораторная №4 разделяет эти функции между Market, Risk и Allocation Agent.